MATHÉMATIQUES ET SCIENCES HUMAINES

PHILIPPE BERNARD DENIS MAUREL

Interrogation en langage naturel d'une base de données : interprétation des adverbiaux de localisation temporelle

Mathématiques et sciences humaines, tome 123 (1993), p. 45-52.

http://www.numdam.org/item?id=MSH 1993 123 45 0>

© Centre d'analyse et de mathématiques sociales de l'EHESS, 1993, tous droits réservés.

L'accès aux archives de la revue « Mathématiques et sciences humaines » (http://msh.revues. org/) implique l'accord avec les conditions générales d'utilisation (http://www.numdam.org/legal. php). Toute utilisation commerciale ou impression systématique est constitutive d'une infraction pénale. Toute copie ou impression de ce fichier doit contenir la présente mention de copyright.



INTERROGATION EN LANGAGE NATUREL D'UNE BASE DE DONNÉES : INTERPRÉTATION DES ADVERBIAUX DE LOCALISATION TEMPORELLE

Philippe BERNARD, Denis MAUREL*

RÉSUMÉ — Cet article présente un travail d'interprétation des adverbiaux de localisation temporelle du français, en vue de l'interrogation d'une base de données. Celle-ci s'effectue par des requêtes en langue naturelle, comprenant des expressions temporelles. L'interprétation de ces adverbiaux, qui passe par la définition d'informations sémantiques associées aux entrées d'un dictionnaire, analyse chaque catégorie de mots : modifieurs, adverbes, noms de temps, déterminants, prépositions, etc., et revient à traduire les expressions temporelles en données qui serviront de points de départ à l'interrogation de la base : une date de début, une date de fin, une heure de début et une heure de fin.

SUMMARY — Natural Language Database Queries: Interpretation of Adverbials of Location in Time. This paper presents a study of the application of French adverbials of location in database queries. Such queries will be formulated using natural language and including temporal adverbials. The interpretation of these adverbials, possible only through reference to the semantic interpretation of the associated dictionary entry, provides an analysis of each word category: modifiers, adverbs, determinants, prepositions, etc. Such an interpretation amounts to a translation of the temporal expressions into data which can be used to query the database: start date, end date, start time, and end time.

1. LE TRAITEMENT AUTOMATIQUE DU LANGAGE NATUREL : CAS DES EXPRESSIONS TEMPORELLES¹

Longtemps limitée au calcul et à la gestion des entreprises, l'informatique se tourne aujourd'hui de plus en plus vers des applications destinées au grand public, les possibilités matérielles et logicielles aidant. Ainsi le langage naturel, qui est le propre de l'homme, apparaît comme le meilleur moyen de dialoguer avec une machine. L'idée de faire communiquer hommes et ordinateurs n'est pas nouvelle et remonte même aux débuts de l'informatique, avec autant d'espoirs que de désillusions. Nous ne tracerons pas ici l'histoire du traitement automatique du langage naturel, la littérature sur ce sujet étant abondante. Citons simplement une synthèse intéressante réalisée par Coulon et Kayser 1986 [5] présentant les applications du traitement automatique du langage naturel et les différents modèles de la langue.

Si l'imperfection du traitement automatique du langage naturel est soulignée dans des domaines tels que la traduction, l'indexation, la correction de textes où il est plutôt question pour l'instant d'assistance au travail humain que d'automatisation complète (cf. par exemple

^{*} Denis Maurel, Institut de Recherche en Informatique de Nantes (IRIN) - 3 rue du Maréchal Joffre, 44041 Nantes cedex 01, France. Tél: (33) 40.30.60.52. Fax: (33) 40.30.60.53. - e-mail: denis.maurel@iut-nantes.univ-nantes.fr.

¹ Les auteurs remercient Henri Labesse pour ses conseils après la lecture d'une première version de cet article.

Carré et al. 1991[4]), on constate en revanche que les systèmes de gestion de bases de données disposent de plus en plus souvent de modules d'interface en langage naturel qui s'interposent entre l'usager et la machine, évitant au premier l'apprentissage d'un langage de requête.

Malgré les progrès réalisés, et compte tenu de la complexité du langage humain, de tels systèmes fonctionnent dans des domaines restreints. C'est ainsi que, dans notre application, nous nous attachons simplement à interpréter des expressions temporelles appartenant à la langue française, dans le but de pouvoir interroger une base de données contenant des horaires de trains. Ce travail d'interprétation, réalisé à l'IRIN (Institut de Recherche en informatique de Nantes) dans le cadre d'un mémoire de DEA d'informatique [1], constitue une suite logique aux travaux effectués sur la reconnaissance des adverbes de date par Denis Maurel, travaux dont les méthodes et résultats ont été exposés dans le numéro 109 de cette revue [10]².

2. INTERPRÉTATION SÉMANTIQUE DES ADVERBIAUX DE LOCALISATION TEMPORELLE

2.1. Interprétation

L'interprétation sémantique concernant la notion de temps dans le langage naturel est un sujet délicat qui a fait l'objet de nombreuses études de la part des linguistes, des informaticiens et des logiciens (cf. entre autres les travaux de Bestougeff et Ligozat [2], ceux de Desclés et al. [6], de Maire-Reppert [7] et Oh [15], ou encore ceux de Molines [13][14] et Bras [3]). Nous ne reprendrons pas ici ces études ambitieuses mais il faut savoir qu'elles ont servi à notre projet dont l'objectif était d'attribuer des interprétations sémantiques à des formes syntaxiques. Il s'agissait en fait de donner des interprétations sémantiques sous forme de dates et d'heures à partir de la reconnaissance des adverbiaux de localisation temporelle, afin de pouvoir interroger une base de données.

Dans les textes en langage naturel, la structure temporelle dépasse le cadre de la date (le 3 juin 92) et de l'heure (à 8 heures). D'autres expressions, plus ou moins floues, peuvent faire référence à une date ou une période (à la fin de la semaine). Si l'adverbe de date le 3 juin 92 est facilement interprétable, grâce à un calendrier, il n'en va pas de même pour l'adverbial fin de semaine qui sera identifié comme une période ayant des bornes représentées chacune par un jour précis du calendrier. Cette interprétation apparaît pour le moins subjective car le simple concept de semaine recouvre au moins deux sens possibles : s'agit-il d'une semaine au sens strict du terme, commençant le dimanche et finissant le samedi ou d'une semaine de travail, du lundi au vendredi? Il en est de même pour la restriction fin de semaine dont l'interprétation peut varier d'une personne à l'autre. Pour pouvoir associer des dates et des heures à des expressions concernant des requêtes en vue de l'interrogation d'une base de données, il est nécessaire d'effectuer au préalable des choix de définition des termes composant l'expression. Pour vers la fin de la semaine, cela revient à attribuer un certain nombre d'informations sémantiques aux trois termes suivants : vers, fin, et semaine, si l'on considère que les mots de et la ne sont pas porteurs de sens.

2.2. Interprétation

Les informations sémantiques diffèrent selon la catégorie grammaticale des termes : préposition, déterminant, prédéterminant, nom de temps, modifieur, adverbe, etc. De même, la valeur de ces informations peut varier d'une application à une autre. Prenons par exemple la préposition avant dans l'expression avant Noël. C'est un trait sémantique attaché à cette préposition qui indique le nombre de jours de la période qui précède Noël. L'interprétation de avant Noël dépendra

²Voir aussi [8], [9], [11] et [12].

directement de ce trait qui dépendra lui-même de l'application. Les informations sémantiques sont associées à chaque entrée d'un dictionnaire des termes apparaissant dans des adverbiaux de localisation temporelle ; elles complètent les informations déjà existantes utilisées par le module de reconnaissance de ces adverbiaux. Le dictionnaire peut être mis à jour à tout moment, en cas d'évolution de l'application informatique qui l'utilise ou en fonction d'une autre application. Notre étude nous a amené à définir quatorze informations sémantiques :

- (1) Le type du mot : un mot peut être, soit non porteur de sens (comme en dans en fin de semaine), soit représentatif d'une période (mois), ou d'une restriction de période (fin), ou encore d'une période relative (lendemain, avant), soit, enfin, représentatif d'une durée (jour, heure).
- (2)(3) La durée : ce sera 1 pour demain, 7 pour semaine, etc. On lui associe son unité (jour, heure ou minute).
- (4)(5) Le nombre de jours : un choix a été fait pour attribuer une valeur quantifiée à certains mots ; par exemple, le mot fin correspond à 3 (en fin de mois renverra au trois derniers jours du mois en question) ; pour d'autres, comme première moitié, c'est une formule de calcul qui s'appliquera par la suite au nom de temps qui suit. Il en est de même pour le nombre d'heures : pour vers il vaut 1 (vers 11h correspondra à la période allant de 10h30 à 11h30).
- (6) La position : le mot troisième correspond à la valeur 3.
- (7)-(9) Le signe qui indique si la référence sur l'axe des temps se fait en avant (après-demain vaut +) ou en arrière (avant vaut -), on lui ajoute son attribut : exclu (avant) et inclu (jusqu'à), et le saut correspondant (2 pour après-demain).
- (10)-(12) La borne de début et la borne de fin de la période de référence : pour *matinée*, nous avons respectivement : 5(h), 12 (h) et jour.
- (13) Le code de priorité associé à chaque nom de temps, de 1 (minute) à 11 (année).
- Une condition booléenne pour calculer si certains mots sont ou non porteurs de sens suivant leur contexte (*jeudi* est porteur de sens dans l'adverbial *jeudi prochain*, mais non dans *jeudi 15 avril*).

Il est important de signaler que les informations utilisées ne sont pas les mêmes pour tous les mots mais dépendent directement de leur propre catégorie grammaticale. Après lecture dans le dictionnaire des mots composant l'expression entrée, le module de reconnaissance des adverbiaux de localisation temporelle (cf. [10]) renvoit au module d'interprétation les informations sémantiques de chaque mot avec leur catégorie grammaticale.

	1	2	3	4	5	6	7	8	9	10	11	12	13
janvier		31	Jour			1							
début	2			3	2	Début							
demain		1	Jour				+		1				
jeudi	1	1	Jour							4	4	semaine	7
lendemain	3	1	Jour				+	Exclu	1		•		5

Exemples d'informations sémantiques

2.3. Adverbiaux traités

L'application distingue trois types d'adverbiaux de localisation temporelle sujets à interprétation :

(1) les adverbes de date : dates et heures

- (2) les adverbes de temps apparentés à une date (aujourd'hui, demain)
- (3) les compléments circonstanciels de temps (dans les 3 jours) qui sont des groupes nominaux en général prépositionnels.

Ces trois types sont traités, mais notre étude s'est limitée aux adverbiaux de référence temporelle qui constituent le seul type de requêtes plausibles que peut donner un utilisateur de notre système : nous avons donc écarté de notre application tous les adverbiaux qui se situent dans le passé par rapport au moment d'énonciation de la requête, tels que hier ou la semaine dernière puisque nous nous intéressons à des renseignements de trains, c'est-à-dire situés dans le futur. Cependant, la gestion des adverbes situés dans le passé ne pose aucun problème puisqu'il suffirait de les rajouter dans le dictionnaire avec des informations sémantiques appropriées.

Etant donné qu'il n'est pas possible d'envisager toutes les expressions temporelles pour une telle application, nous nous sommes limités dans notre étude à un lexique d'environ deux cents quatre-vingts mots, taille bien suffisante pour offrir une grande complexité de réponses possibles au système. En fait, rien n'empêche d'envisager l'élargissement ultérieur du lexique ou son adaptation à une autre base de données, dans le cadre d'une autre application. Là aussi, il suffirait de rajouter dans le dictionnaire les mots qui nous intéressent ou bien encore de modifier la valeur des informations sémantiques des différents termes qui y figurent.

Le lexique utilisé est un extrait du dictionnaire de [9] et comporte aussi bien des mots simples, comme *demain*, que des mots composés, comme *à peu près*. Cependant, pour les besoins de l'interprétation, le dictionnaire a été complété par des informations sémantiques.

D'autres types d'adverbiaux, comme les coordinations (lundi ou mercredi) ou les exclusions (cette semaine, sauf mercredi) ne sont pas traités actuellement, mais le seront par la suite.

3. DE LA RECONNAISSANCE À L'INTERPRÉTATION

Dans une première étape, l'utilisateur saisit sa requête en langage naturel, par exemple : je souhaite partir lundi prochain en fin de matinée (supposons que cette saisie ait lieu le vendredi 1er janvier 1993 à midi).

Puis s'effectue le lancement du module de reconnaissance. Dans la réponse ci-dessus, l'expression temporelle reconnue est *lundi prochain en fin de matinée*.

Le module de reconnaissance renvoit à celui d'interprétation la liste des mots de l'expression temporelle reconnue ainsi que, pour chacun d'eux, leur catégorie grammaticale et leurs informations sémantiques, après lecture du dictionnaire. A l'aide de ces données, le programme d'interprétation va transformer l'expression temporelle en une période en dates et en heures, soit, pour l'expression ci-dessus, du 04/01/93 au 04/01/93, de 10h à 12h.

L'interprétation des expressions temporelles reconnues s'effectue en neuf phases :

3.1. Elimination des mots "non porteurs de sens"

les démonstratifs, les articles, certaines prépositions (à, durant, en,...), etc. Certains autres mots (dans, mois, prochain, ...) peuvent être également non porteurs de sens, dans certains contextes d'utilisation, ce qui est noté dans leur information sémantique par une condition booléenne (voir supra §2.2). Le programme teste cette condition pour chaque mot de l'expression qui contient une telle information et élimine tous ceux dont l'information "non porteur de sens" est vraie.

ce jour

-> jour

3.2. Regroupement des déterminants numériques

avec le(s) mot(s) associé(s) et interprétation des expressions numériques. L'interprétation peut donner lieu à une durée (3 jours), une période en jours (mars 93), une période en heures (dans les 3 heures), une date (15 mai) ou une heure (16 heures 30). à dix-sept heures trente et une

- -> dix-sept heures trente et une (cf. 3.1)
- -> ((17 heures) 31)

3.3. Regroupement des modifieurs

prochain, à venir, premier,... avec leur(s) mot(s) associé(s) et calcul de l'interprétation correspondante.

Exemples de regroupements (MO=modifieur, NT=nom de temps)

Structure	Exemple		
(MO NT)	le prochain week-end		
(NT MO)	la semaine prochaine		
(NT MO) NT	lundi prochain au matin		
((NT NT) MO)	lundi matin prochain		
(MO (NT NT))	le premier week-end du mois		

Les mots de l'expression sont examinés un par un à partir du dernier. Pour chaque mot de classe modifieur, le système détermine le nom de temps avec lequel il doit être interprété. Cela ne pose aucun problème lorsqu'il n'y a qu'un seul nom de temps dans l'expression (les deux premiers exemples). Par contre, lorsque deux noms de temps figurent dans l'expression à interpréter, on risque une ambiguïté d'interprétation (lequel choisir?). Celle-ci est levée en tenant compte de la structure de l'expression :

- Si la structure est NT MO NT ou NT NT MO (3ème et 4ème exemples), le système interprète le modifieur avec le nom de temps qui possède (dans son information sémantique) le code priorité le plus grand, conformément à la liste ci-dessous :
 - 1: minute
 - 2: heure
 - 3: aube, aurore, crépuscule
 - 4: après-midi, matin, matinée, midi, soir, soirée, tantôt
 - 5: avant-veille, lendemain, surlendemain, veille
 - 6: jour, journée
 - 7: lundi, mardi, etc, dimanche
 - 8: week-end
 - 9: semaine
 - 10: mois
 - 11: an, année

Ainsi, dans l'exemple *lundi prochain au matin*, *prochain* est interprété avec *lundi* (priorité=7) et non *matin* (priorité=4). Ce dernier sera interprété plus loin (en phase 6).

- Si la structure est MO NT NT (5ème exemple), le modifieur est interprété avec les deux noms de temps qui forment alors un tout :

le premier week-end du mois

- -> premier week-end du mois (cf. 3.1)
- -> premier (week-end du mois)

Le calcul se fera bien sûr toujours vers le futur, pour correspondre à notre application. Ainsi, le 1^{er} janvier 1993, la réponse sera le week-end du 2-3 janvier, alors que le 8 janvier, la réponse correspondra au week-end du 6-7 février.

3.4. Interprétation des adverbes de temps

aujourd'hui, demain, après-demain

Le résultat est la journée correspondante, avec éventuellement une restriction sur la période en heure (comme dans *demain*, *vers midi*);

3.5. Interprétation des noms de fête

Noël, Pâques,...

Le programme recherche tout d'abord la date de la fête en question, puis le calcul se fait normalement à partir de cette date. Par exemple, si nous supposons toujours être le 1^{er} janvier 1993 à midi :

Trois jours avant Pâques

- -> 3 jours avant Pâques (cf. 3.2)
- -> 3 jours avant 11 avril 1993

3.6. Interprétation des noms de temps

mois, matinée, semaine,... Il s'agit ici d'interpréter les noms de temps dans des expressions telles que ce matin, au début de l'après-midi, en milieu de semaine. Dans certains cas, les noms de temps peuvent être interprétés dans des étapes antérieures, soit en les regroupant avec un déterminant numérique (dans les trois jours, deux jours avant Noël), soit, comme on l'a vu en phase 3, par regroupement avec un modifieur (la semaine prochaine, le week-end à venir).

3.7. Interprétation des déterminants

début, fin, moitié... Chaque déterminant est interprété avec le mot qui le suit (la fin de la semaine). L'expression à interpréter est examinée mot par mot à partir de la droite, dans le but de traiter les cas où plusieurs déterminants se succèdent.

3.8. Interprétation des prépositions

dès, vers,... Chaque préposition est interprétée avec le mot (ou le groupe de mots) qui la suit. Trois cas se présentent :

- avant la semaine prochaine, après la fin de la matinée, à partir de 16 heures.

L'interprétation d'une préposition consiste en le calcul d'une période finale à partir d'une période initiale définie par les mots qui la suivent. Ce calcul est déterminé par l'intermédiaire des informations sémantiques de la préposition, notamment celle qui indique si la période finale se situe avant (1^{er} exemple) ou après (2ème et 3ème exemples) la période initiale, et celle qui précise l'inclusion (3ème exemple) ou la non inclusion (1^{er} et 2ème exemples) de la borne.

- trois jours avant Noël

La préposition est alors précédée d'un groupe de mots indiquant une durée. C'est la neuvième information sémantique, le saut, qui permet l'interprétation de cette expression : ici, elle prend la valeur de la durée, c'est-à-dire 3, et indique que trois jours séparent la période initiale de la période finale.

- dans trois jours, d'ici trois jours

Cette fois, la préposition est suivie d'un groupe de mots indiquant une durée. L'interprétation de ces expressions s'effectue en fonction du signe de la préposition. Dans le premier exemple, il est positif et indique alors un saut (de trois jours) à effectuer à partir de la date du jour. Dans le second, il est négatif. Dans ce cas, la période correspondant à l'interprétation débute à la date du jour et s'achève 3 jours après.

3.9. Interprétation des prédéterminants

environ, exactement,... Chaque prédéterminant est interprété avec le mot suivant ou le mot précédent, selon un ordre de précision qui se présente ainsi : heure (16 heures), période en heures (matin), jour (demain), période en jours (la semaine prochaine). Par exemple, dans l'expression demain environ à 16 heures, le prédéterminant sera interprété avec 16 heures et non avec demain...

4. DE L'INTERPRÉTATION À L'INTERROGATION

Le résultat de l'interprétation des différents termes composant l'expression temporelle consiste en quatre valeurs qui caractérisent l'interprétation de l'expression reconnue : une date de début, une date de fin, une heure de début et une heure de fin. A l'aide de ces quatre données, le programme peut ensuite, dans une dernière étape, interroger la base de données. Celle-ci contient tous les horaires des TGV entre Paris et Nantes mais pourrait bien sûr être étendue.

Si l'expression temporelle est, par exemple, la semaine prochaine en début d'après-midi, nous obtiendrons les quatre données suivantes (en supposant toujours que nous sommes le vendredi 1^{er} janvier 1993 à midi):

Résultat de l'analyse

date de début	dimanche 3/1/93
date de fin	samedi 9/1/93
heure de début	12 heures
heure de fin	14 heures

Le programme fournira donc la liste des TGV circulant entre Paris et Nantes du 3 au 9 janvier 1993, de 12 heures à 14 heures :

Réponses fournies

Requête	la semaine prochaine en début d'après-midi					
Période	du 3/1/93 au 9/1/93 de 12h à 14h					
Date	Heure de départ	Heure d'arrivée	Tarif			
3/1/93	13h50	16h02	1			
4/1/93	13h50	16h02	1			
5/1/93	13h50	16h02	1			
6/1/93	13h50	16h02	1			
7/1/93	13h50	16h02	1			
8/1/93	13h50	16h02	3			
8/1/93	13h45	15h47	3			
9/1/93	13h50	16h02	1			
9/1/93	13h45	15h47	1			

```
Il en est de même pour chaque type de question : ce jour (cf. 3.1)
```

- -> (1/1/93, 1/1/93, 12h, 24h)
- à dix-sept heures trente et une (cf. 3.2)
 - -> (1/1/93, 1/1/93, 17h31, 17h31)

le premier week-end du mois (cf. 3.3)

- -> (2/1/93, 3/1/93, 5h, 24h)
- demain, vers midi (cf. 3.4)
 - -> (2/1/93, 2/1/93, 11h30, 12h30)

Trois jours avant Pâques (cf. 3.5)

-> (8/3/93, 8/3/93, 5h, 24h)

etc.

Ce résultat montre que la reconnaissance des adverbiaux de localisation temporelle proposée par [10] permet leur interprétation lorsque le contexte détermine un point de référence pour le calcul (ici, la date et l'heure de l'interrogation de la base).

BIBLIOGRAPHIE

- [1] BERNARD, P., Interrogation en langage naturel d'une base de données, interprétation des adverbes de temps du français, mémoire de DEA d'Information Scientifique et Technique (Université Paris VII), Paris, 1992.
- [2] BESTOUGEFF, H., LIGOZAT G., Outils logiques pour le traitement du temps, De la linguistique à l'intelligence artificielle, Paris, Masson, 1989.
- [3] BRAS, M., Calcul des structures temporelles du discours, Toulouse, Thèse de Doctorat (Université Paul Sabatier), 1990.
- [4] CARRÉ, R., DÉGREMONT, J.F., GROSS, M., PIERREL, J.M., SABAH, G., Langage humain et machines, Paris, Presse du CNRS, 1991.
- [5] COULON, D., KAYSER, D., "Informatique et langage naturel, Présentation générale des méthodes d'interprétation des textes écrits", *Technique et Science Informatiques*, février 1986, 103-124.
- [6] DESCLÉS, J.P., JOUIS, C., OH, H.G., REPPERT D., Segond F., Représentations et recherches des valeurs sémantiques des temps de l'indicatif du français pour une mise en oeuvre informatique, CAMS, GDR 957, n°1, Paris, 1991.
- [7] MAIRE-REPPERT, D., Les temps de l'indicatif du français en vue d'un traitement informatique, l'imparfait, Paris, Thèse de Doctorat (Université Paris IV), 1991.
- [8] MAUREL, D., "Grammaire des dates, étude préliminaire à leur traitement automatique", Linguisticae Investigationes, vol. 12 (1988), n°1, 101-128.
- [9] MAUREL, D., Reconnaissance de séquences de mots par automate, adverbes de date du Français, Paris, Thèse de Doctorat (Université Paris VII), 1989.
- [10] MAUREL, D., "Description par automate des dates et des adverbes apparentés", Mathématiques, Informatiques et Sciences humaines, n° 109 (1990), 5-16, Paris.
- [11] MAUREL, D., "Adverbes de date, étude préliminaire à leur traitement automatique", Linguisticae Investigationes, vol. 14 (1990), n°1, 31-63.
- [12] MAUREL, D., "Préanalyse des adverbes de date du français", *TA information*, volume 32 (1991), n°2, 5-17, Paris.
- [13] MOLINES, F., Adverbes de localisation temporelle à base de noms de temps, Mémoire de maîtrise (Université de Toulouse le Mirail), Toulouse, 1988.
- [14] MOLINES, F., Acceptabilité et interprétation des adverbiaux de localisation temporelle, grammaire ou dictionnaire?, Mémoire de DEA (Université de Toulouse le Mirail), Toulouse, 1989.
- [15] OH. H. G., Représentation des valeurs sémantiques du passé composé français en vue d'un traitement informatique, Paris, Thèse de Doctorat (Université Paris IV), 1991.